# 料金見積

画像解析APIの月額コスト見積。リクエスト規模別に算出。

## 前提条件

- リージョン: ap-northeast-1（東京）
- 料金は2026年3月時点のAWS公式料金に基づく（税別・USD）
- 1リクエストあたりの画像: 1枚
- Lambda実行時間: 平均5秒（OpenAI API呼び出し含む）

## リソース構成

| リソース | 仕様 | 根拠 |
|---|---|---|
| API Gateway | REST API, Regional | api/template.yaml |
| Lambda | Python 3.12, 512MB, タイムアウト60秒 | api/template.yaml |
| Cognito | User Pool（管理者作成のみ） | api/template.yaml |
| S3 | Standard, SSE-AES256 | web/template.yaml |
| CloudFront | PriceClass_200, HTTP/2+3 | web/template.yaml |
| CloudFront Function | IP制限 + パスリライト | web/template.yaml |
| Route53 | Aレコード（エイリアス） | web/template.yaml |
| ACM | SSL証明書（us-east-1） | web/template.yaml |
| SSM Parameter Store | OpenAI APIキー（1パラメータ） | api/template.yaml |

## AWSリソースコスト

### 固定費（リクエスト数に依存しない）

| リソース | 月額 | 備考 |
|---|---|---|
| Route53 ホストゾーン | $0.50 | 1ゾーンあたり |
| ACM証明書 | $0.00 | 無料 |
| SSM Parameter Store | $0.00 | Standard パラメータは無料 |
| **小計** | **$0.50** | |

### 従量費

| リソース | 単価 | 100件/月 | 1,000件/月 | 10,000件/月 |
|---|---|---|---|---|
| API Gateway | $4.25/100万リクエスト | $0.00 | $0.00 | $0.04 |

| リソース | 単価 | 100件/月 | 1,000件/月 | 10,000件/月 |
|---|---|---|---|---|
| Lambda リクエスト | $0.20/100万リクエスト | $0.00 | $0.00 | $0.00 |
| Lambda 実行時間 | $0.0000083334/GB秒 | $0.00 | $0.02 | $0.21 |
| CloudFront | $0.114/10,000リクエスト (日本) | $0.00 | $0.01 | $0.11 |
| S3 | $0.025/GB + $0.0047/1,000リクエスト | $0.00 | $0.00 | $0.00 |
| Cognito | 50,000 MAUまで無料 | $0.00 | $0.00 | $0.00 |
| **小計** | | **$0.00** | **$0.03** | **$0.36** |

**Lambda実行時間の計算根拠**

```
メモリ: 512MB = 0.5GB
実行時間: 平均5秒/リクエスト
GB秒単価: $0.0000083334

10,000件の場合:
0.5GB × 5秒 × 10,000件 = 25,000 GB秒
25,000 × $0.0000083334 = $0.21
（無料枠 400,000 GB秒/月を超えない限り実質無料）
```

# OpenAI APIコスト（主要コスト）

## モデル別単価

| モデル | 入力単価 (/1Mトークン) | 出力単価 (/1Mトークン) |
|---|---|---|
| gpt-4.1-mini | $0.40 | $1.60 |
| gpt-4.1 | $2.00 | $8.00 |

## 1リクエストあたりのトークン見積

| 項目 | トークン数 | 備考 |
|---|---|---|
| システムプロンプト | ~150 | 固定（判定指示文） |
| 画像トークン（detail=low） | ~85 | 低解像度モード固定 |
| 画像トークン（detail=high） | ~800 | 高解像度モード |
| ユーザープロンプト | ~30 | 判定対象の指定 |
| 出力（JSON応答） | ~100 | found/answer/confidence |

## モデル別・規模別コスト

**gpt-4.1-mini（デフォルト、detail=low）**

| 項目 | 1リクエスト | 100件/月 | 1,000件/月 | 10,000件/月 |
|---|---|---|---|---|
| 入力 (~265トークン) | $0.000106 | $0.01 | $0.11 | $1.06 |
| 出力 (~100トークン) | $0.000160 | $0.02 | $0.16 | $1.60 |
| **小計** | **$0.000266** | **$0.03** | **$0.27** | **$2.66** |

**gpt-4.1（高精度、detail=low）**

| 項目 | 1リクエスト | 100件/月 | 1,000件/月 | 10,000件/月 |
|---|---|---|---|---|
| 入力 (~265トークン) | $0.000530 | $0.05 | $0.53 | $5.30 |
| 出力 (~100トークン) | $0.000800 | $0.08 | $0.80 | $8.00 |
| **小計** | **$0.001330** | **$0.13** | **$1.33** | **$13.30** |

**gpt-4.1-mini（detail=high）**

| 項目 | 1リクエスト | 100件/月 | 1,000件/月 | 10,000件/月 |
|---|---|---|---|---|
| 入力 (~980トークン) | $0.000392 | $0.04 | $0.39 | $3.92 |
| 出力 (~100トークン) | $0.000160 | $0.02 | $0.16 | $1.60 |
| **小計** | **$0.000552** | **$0.06** | **$0.55** | **$5.52** |

# 月額合計

gpt-4.1-mini / detail=low（推奨構成）

| 規模 | AWS固定費 | AWS従量費 | OpenAI API | 合計 |
|---|---|---|---|---|
| 100件/月 | $0.50 | $0.00 | $0.03 | **$0.53** |
| 1,000件/月 | $0.50 | $0.03 | $0.27 | **$0.80** |
| 10,000件/月 | $0.50 | $0.36 | $2.66 | **$3.52** |

gpt-4.1 / detail=low（高精度構成）

| 規模 | AWS固定費 | AWS従量費 | OpenAI API | 合計 |
|---|---|---|---|---|
| 100件/月 | $0.50 | $0.00 | $0.13 | **$0.63** |
| 1,000件/月 | $0.50 | $0.03 | $1.33 | **$1.86** |
| 10,000件/月 | $0.50 | $0.36 | $13.30 | **$14.16** |

# コスト構造の特徴

1. **OpenAI APIが支配的**: AWSインフラコストは月額$1未満。コストの大半はOpenAI API利用料
2. **モデル選択が最大の変動要因**: gpt-4.1はgpt-4.1-miniの約5倍のコスト

3. **detail設定の影響**: detail=highは画像トークンが約10倍になるが、出力コストは変わらない
4. **AWS無料枠**: Lambda（100万リクエスト/月、400,000 GB秒/月）の範囲内であれば実行コストはほぼゼロ
5. **Cognito**: 50,000 MAU以下は無料。本システムの想定利用者数では課金対象外

## 注意事項

- 上記はリクエスト処理のみのコスト。データ転送量（CloudFront → クライアント）は含まない
- OpenAI APIの料金は変更される可能性がある
- Lambda無料枠はAWSアカウント全体で共有。他サービスとの共用時は枠を超える可能性あり
- 為替レート（USD/JPY）の変動により円建てコストは変動する